Thesis review study

Attention Is All You Need

조은비, 전민하

Abstract

- 기존에는 시퀀스간 변형을 활용한 RNN, CNN 기반 모델이 많이 사용됐다.
- 그중 가장 좋은 성능을 보인 모델은 인코더, 디코더 아키텍처에 Attention 매커니즘을 활용한 모델이었다.
- 이에 본 논문은 recurrence, convolutions를 제거하고 오직 Attention 매커니즘에 기반한 ‘Transformer’ 아키텍처를 소개한다.
- Transformer는 영어를 독일어, 불어로 번역하는 과정에서 기존 모델보다 더 개선된 성능을 보여줬다.

AGENDA

01

Introduction

Recurrent models

시퀀스에 포함된 각각의 토큰들에 대한 순서 정보를 먼저 정렬시킨 뒤에 반복적으로 입력으로 넣어서 hidden state 값을 갱신시키는 방식. 토큰 개수만큼 뉴럴 네트워크에 입력을 넣어야 해서 병렬적 처리가 어렵다. 메모리, 속도 측면 비효율성 야기.

Attention mechanisms

출력 단어를 만들때마다 어떤 정보가 가장 중요한지 가중치를 부여하고, 가중치가 적용돼 곱해진 hidden state 값을 사용한다.

Transformer

Recurrence 속성을 완전히 없애버리고, 완전히 Attention mechanisms에 의존했다. 한번의 행렬곱에 위치정보가 포함된 전체 시퀀스를 처리할 수 있다. 순차적인 입력이 아니라서 병렬처리가 가능하다. 성능이 훨씬 좋아졌다.

02

Backgroud

Self-Attention

본 논문에서는 전적으로 Self-Attention에 의존해 최초로 시퀀스간 변형이 가능한 네트워크를 만들었다.

- Self-Attention은 문장 스스로 Attention을 수행해서 representation을 학습하게 한다.

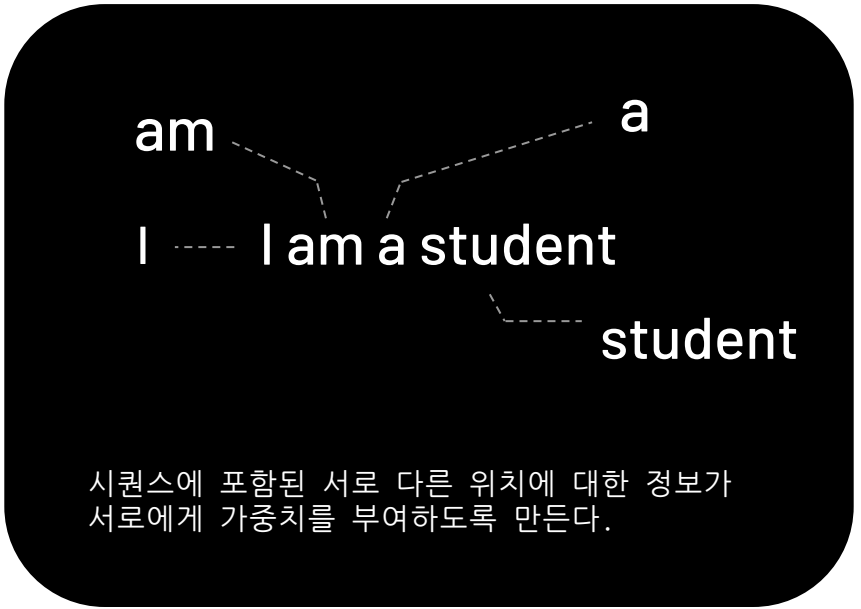

03

Model Architecture

3.1 Encoder and Decoder Stacks

참고) 본 논문에서는 인코더와 디코더 레이어를 6번 쌓을 수 있게 만들었고, multi-head attention 수행 시 인코더의 output 값에 attention을 수행할 수 있게 했다.

1-5 과정을 N번만큼 반복. 총 N개의 인코더 레이어가 반복 수행된다. 이후 마지막 출력값을 디코더에서 사용할 수 있도록 한다.

이후 Feed Forward 레이어, Linear 레이어를 거치고 Softmax를 해서 각각의 출력 문장에 포함된 단어들이 어떤 단어에 해당하는지 구할 수 있도록 한다.

5 Add&Norm 후 정규화를 한다. 이후 Feed Forward 레이어를 거치고 정규화를 하기 전까지는 입출력 디멘젼이 같다.

4 Multi-Head Attention은 쿼리, 키, 벨류 값이 동일하며 self attention으로 동작한다.

3 쿼리, 키, 벨류로 복제돼 입력된다.

2 문장에 포함된 각 단어의 위치정보를 인코딩해서 입력하기 위함

1 입력 임베딩과 같은 디멘젼으로 합쳐서 임베딩 벡터로 사용

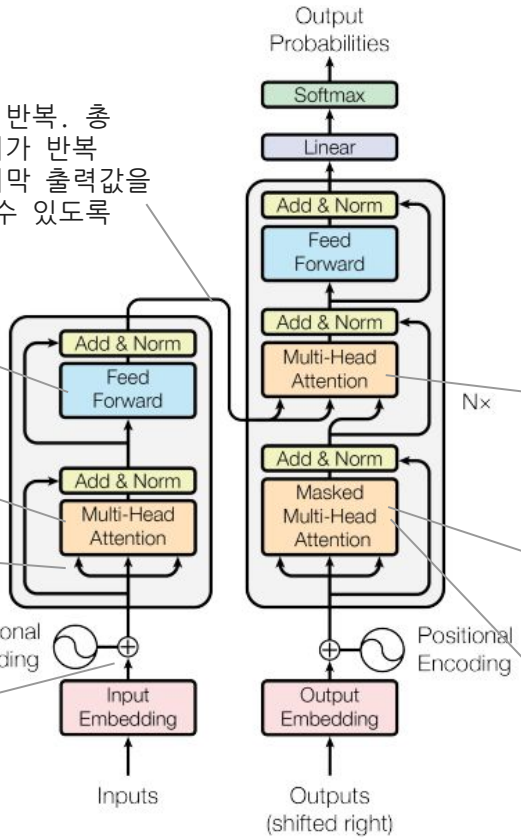

Figure 1: The Transformer - model architecture.

디코더 파트의 두번째 Attention에서는 키, 벨류값이 인코더 파트에서 왔고, 쿼리 값은 디코더에 있기 때문에 인코더 파트에서 어떤 정보를 참고해야 하는지에 대해 Attention을 수행한다.

학습 수행 시 Mask를 씌워서 뒤쪽에 있는 단어를 미리 알지 못하도록 한다. 이전에 등장한 단어만 참고해서 Attention할 수 있다.

디코더 파트의 첫번째 Attention은 쿼리, 키, 벨류 값이 같아서 Self Attention이 수행된다.

3.2 Attention

쿼리는 특정 키에게 질문을 하는 주체. 키는 attention을 수행할 대상을 의미한다. 쿼리가 키에게 ‘I am happy’ 중에 어떤 단어가 제일 중요해? 라고 질문하는 것과 같다.

3.2.1 Scaled Dot-Product Attention

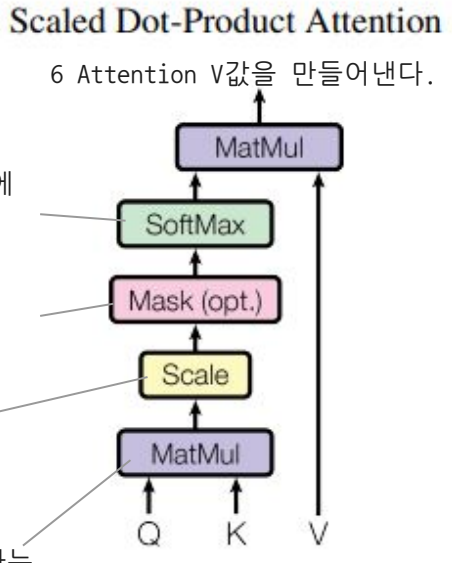

6 Attention V값을 만들어낸다.

4 Softmax를 통해 각각의 키에 대해 중요도를 파악하는 값을 확률 형태로 바꿔준다.

3 필요할 때 선택적으로 사용

2 Softmax에 들어가는 값을 스케일링 하기 위해 scale 레이어를 포함한다.

1 쿼리가 키에게 질문하는 게 행렬곱으로 이뤄진다.

5 그렇게 나온 확률값을 각각 벨류와 곱해서

3.2.2 Multi-Head Attention

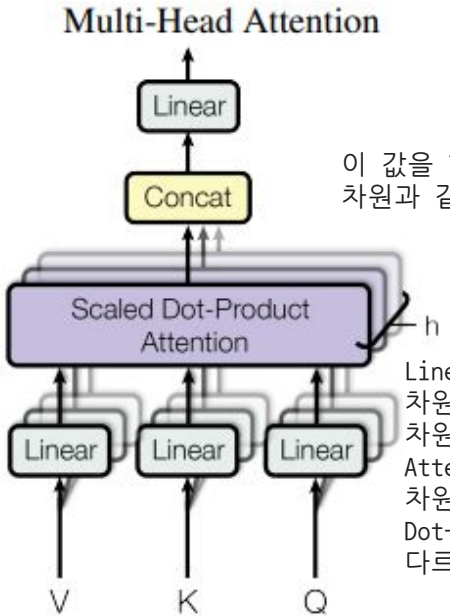

이 값을 합쳐서 기존의 임베딩 차원과 같게 만든다.

Linear 레이어는 임배딩 차원을 키, 벨류, 쿼리의 차원으로 바꾼다. 이후 Attention을 수행해서 동일한 차원이 나오게 되면 Scaled Dot-Product를 head마다 서로 다르게 수행한다.

입력값은 벨류, 키, 쿼리에 각각 복제가 돼 들어갈 수 있다.

multi-head attention은 Transformer에서 위치마다 다른 방식으로 쓰였다.

encoder-decoder attention	• 쿼리는 디코더에서 오고, 키, 벨류값은 인코더 출력에서 가져온다. • 소스문장의 문장들 중에 어떤 단어에 집중해야 하는지를 계산하는 과정
encoder contains self-attention	• 인코더 파트에서 사용. • 쿼리, 키, 벨류가 모두 같다.
self-attention	• 디코더 파트. 맨 처음에 입력 임베딩 들어왔을 때 self-attention 수행. • 마스크 씌워서 소프트맥스에 들어가는 값이 -무한대가 될 수 있도록 하고, 각 단어가 미리 등장했던 단어만 참고할 수 있도록 했다.

$$\mathrm{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

- FFN: 인코더와 디코더에서 공통으로 가지고 있는 서브층
- 각 단어의 위치별로 독립적이고 동일하게 적용

  -> 모든 단어가 같은 FFN 네트워크를 거침
- 차원: 인코더에 처음 넣었을 때의 input과 동일

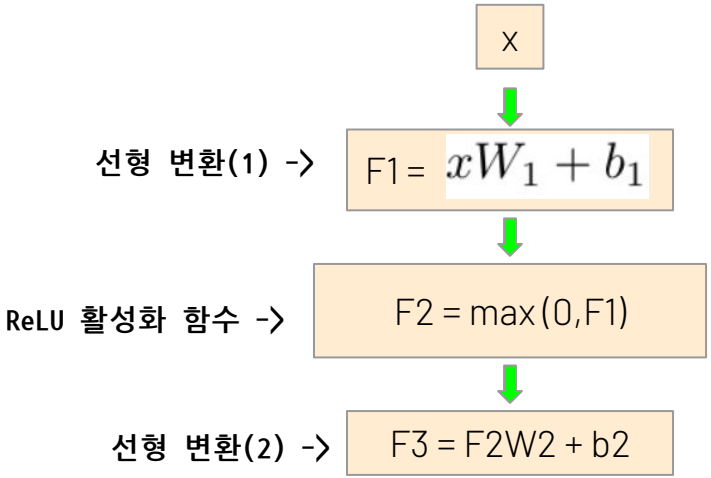

- Parameter (W, b)
- 각 레이어마다 다른 값 사용
- 같은 레이어 내에서는 동일한 값을 사용

input과 output의 token들을 embedding

- 입력과 출력 토큰을 dmodel 차원의 벡터로 변환하기 위해 학습된 임베딩을 사용
- decoder 출력에서 다음 토큰 예측 확률을 얻기 위해 학습된 선형 변환과 softmax 함수를 사용.
- 두 embedding layer와 softmax 이전 선형 변환 사이에서 동일한 가중치 행렬을 공유.

RNN: 순차적으로 cell에 입력되므로, 토큰의 위치(순서)정보가 보존됨

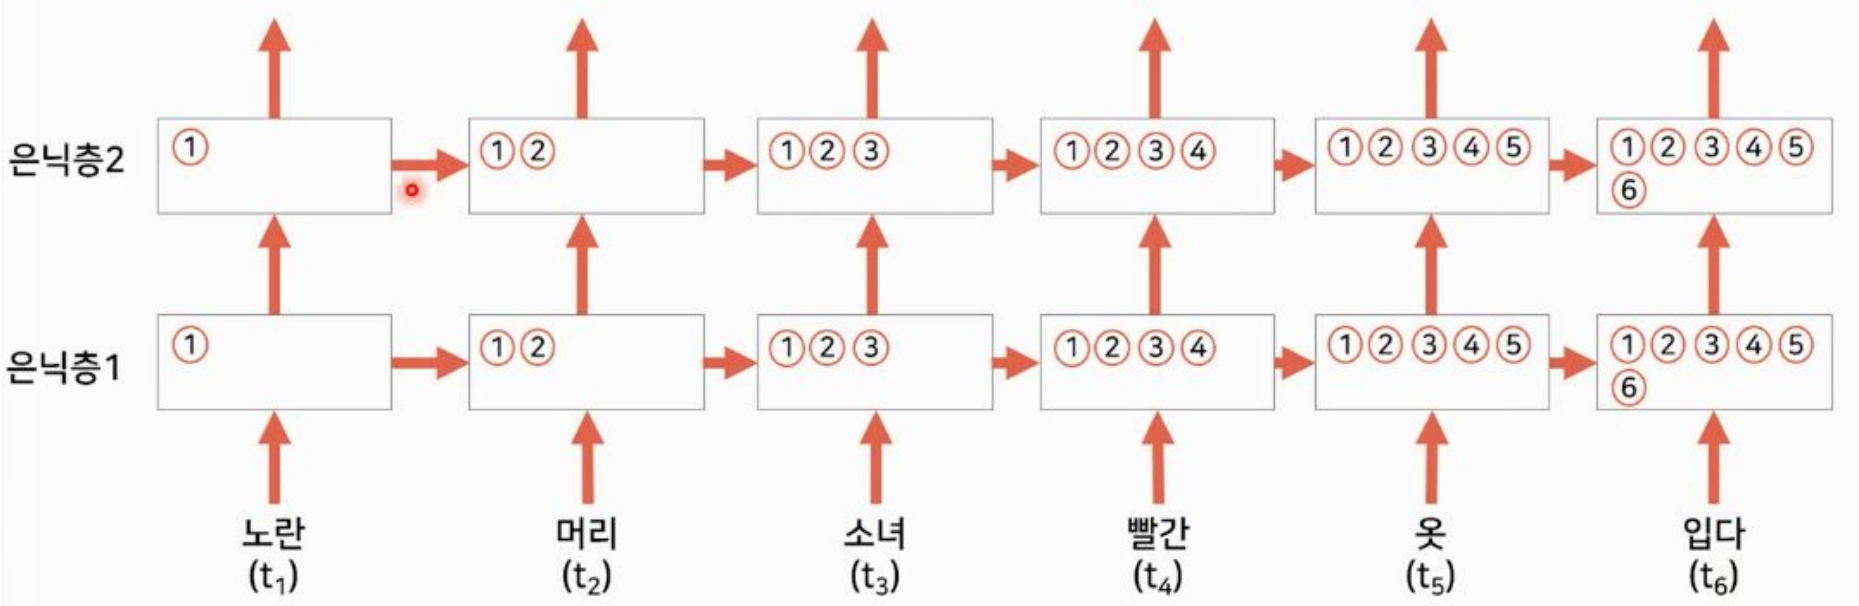

Input Embedding: Input에 입력된 데이터를 컴퓨터가 이해할 수 있도록 행렬 값으로 변환

- 각각의 벡터 차원은 해당 단어의 피처 값을 보유함
- 서로 다른 단어의 피처값이 유사할 수록 벡터 공간의 임베딩 벡터는 가까워짐

주기함수인 사인 코사인 함수 이용 *-> 상대적인 위치 정보를 얻기 용이함*

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

i가 짝수: sin 함수 사용
i가 홀수: cos 함수 사용

- pos: position
- i: 차원
  - 위치 정보를 표현하는 positional embedding의 차원 == 단어 임베딩의 차원
- d_model: transformer의 인코더, 디코더에서 정해진 입출력의 크기

Transformer - 토큰을 한번에 병렬로 처리하므로 단어의 순서를 **알 수 없음!**

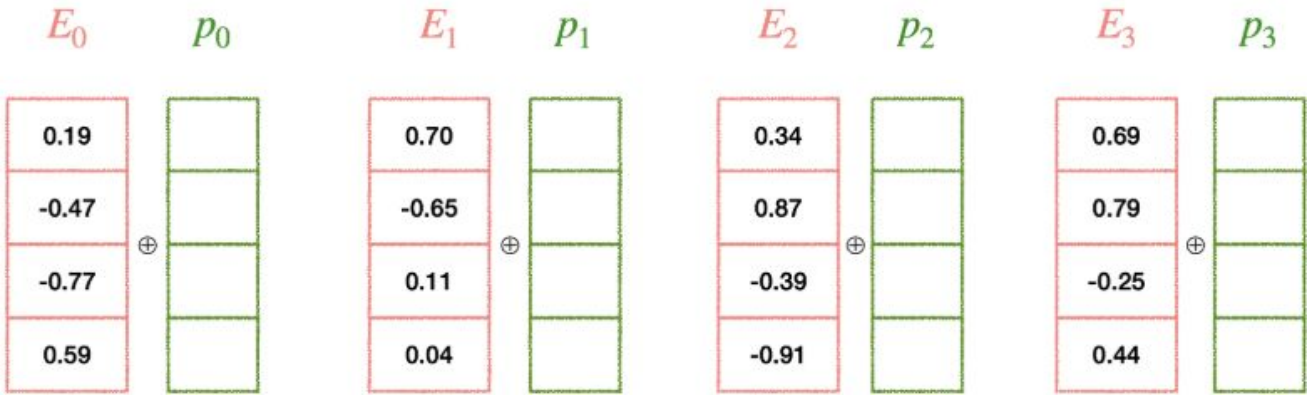

- 각 단어 벡터 + positional encoding을 통해 얻은 위치 정보
  -> 시공간적 속성이 임베딩된 벡터가 생성, 시퀀스 정보가 보존!

04

Why Self-Attention?

Self-Attention
VS
Recurrent Layer
VS
Convolutional Layer

〈주요 비교 요소〉

1. **계산 복잡도**: 각 레이어에서 필요한 계산량.
2. **병렬 처리 가능성**: 계산을 병렬화할 수 있는 능력, 최소 순차적 연산 횟수로 측정.
3. **장기 의존성 학습의 경로 길이**: 입력과 출력 시퀀스 간의 신호가 얼마나 빨리 전달될 수 있는지,
   즉 장기 의존성을 학습할 수 있는 용이성.

입력 데이터의 첫 단어가 출력 데이터의 마지막에 영향을 미치는 정도

4. Why Self-Attention?

	Self-Attention	Recurrent Layer	Convolutional Layer
계산 복잡도	일정한 수의 연산으로 모든 위치 연결	O(n)O(n)O(n) 순차적 연산 필요	합성곱 커널에 따라 다름. O(nk)O(nk)O(nk) ¦ O(logkn)O(\log_kn)O(logkn)
병렬화 가능성	높음	낮음 (순차적 처리)	병렬화 가능, but 순차적 처리로 인해 복잡도 증가
장기 의존성 학습	경로가 짧아서 용이	경로가 길어서 어려움	경로가 길어서 어려움
최대 경로 길이	일정한 수의 연산으로 연결됨	O(n)O(n)O(n) 순차적 경로	O(nk)O(nk)O(nk) ¦ O(logkn)O(\log_kn)O(logkn)
계산 효율성	시퀀스 길이가 짧을 때 효율적, 매우 긴 시퀀스에서 이웃만 고려 시 성능 개선 가능	비교적 느림 (순차적 연산)	많은 연산 필요
해석 가능성	각 주의 헤드가 구문적 및 의미적 구조와 관련된 행동을 학습	어려움	어려움

- **Self-Attention**은 계산 효율성, 병렬화가 용이하고, **장기 의존성 학습에 유리함**.

  시퀀스의 모든 단어를 한번에 고려할 수 있기 때문

05

Training

영어 - 독일어

- 약 450만 문장 쌍
- 바이트-쌍 인코딩(BPE) 사용
- 약 37,000개 어휘 토큰

영어 - 프랑스어

- 약 3,600만 문장 쌍
- 워드피스 토큰화
- 약 32,000개 어휘 토큰

배치 방식: 문장 쌍을 시퀀스 길이에 맞게 배치, 각 배치에 소스와 타겟 토큰 각각 약 25,000개 포함

5.1 Training Data and Batching

영어 - 독일어

- 약 450만 문장 쌍
- 바이트-쌍 인코딩(BPE) 사용
- 약 37,000개 어휘 토큰

영어 - 프랑스어

- 약 3,600만 문장 쌍
- 워드피스 토큰화
- 약 32,000개 어휘 토큰

배치 방식: 문장 쌍을 시퀀스 길이에 맞게 배치, 각 배치에 소스와 타겟 토큰 각각 약 25,000개 포함

5.2 Hardware and Schedule

- **하드웨어**: 8개의 NVIDIA P100 GPU가 장착된 하나의 머신
- **훈련 시간**:
  - ★ Base 모델: 훈련 100,000단계 (12시간)
  - ★ Big 모델: 훈련 300,000단계 (3.5일)
- **훈련 속도**: Base 모델의 각 훈련 단계는 약 0.4초, Big 모델은 1.0초 소요

$$lrate = d_{\text{model}}^{-0.5} \cdot \min(step\_num^{-0.5}, step\_num \cdot warmup\_steps^{-1.5})$$

Adam

Learning rate scheduler(학습률 스케줄링): 학습률을 동적으로 변화

- 훈련 초기에는 학습률을 선형적으로 증가시키고, 이후에는 step number(단계 수)의 inverse square root(역제곱근)에 비례하여 감소
- warmup_steps = 4000

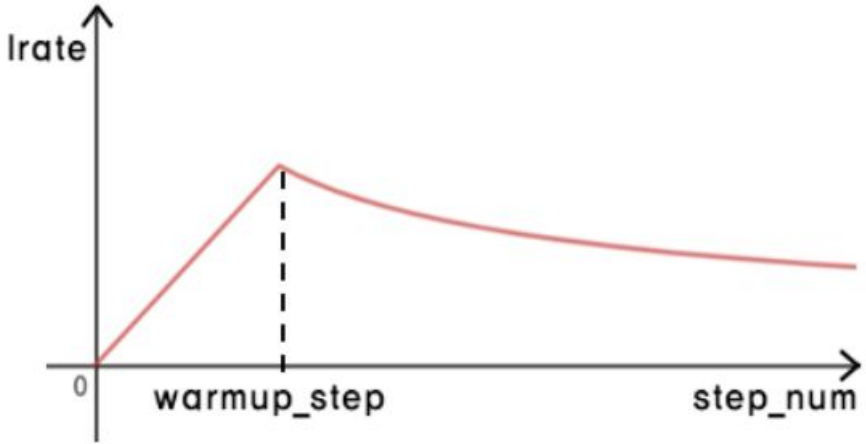

$$lrate = d_{\text{model}}^{-0.5} \cdot \min(step\_num^{-0.5}, step\_num \cdot warmup\_steps^{-1.5})$$

Adam

Learning rate scheduler(학습률 스케줄링): 학습률을 동적으로 변화

- 훈련 초기에는 학습률을 선형적으로 증가시키고, 이후에는 step number(단계 수)의 inverse square root(역제곱근)에 비례하여 감소
- warmup_steps = 4000

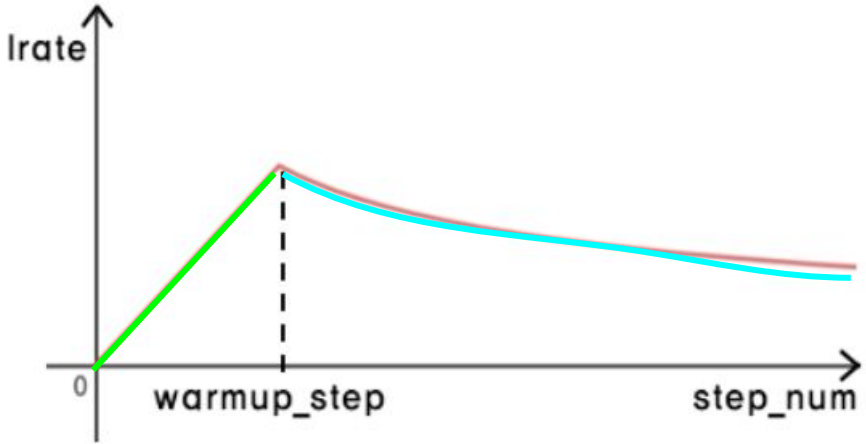

$$lrate = d_{\text{model}}^{-0.5} \cdot \min(step\_num^{-0.5}, step\_num \cdot warmup\_steps^{-1.5})$$

Adam

Learning rate scheduler(학습률 스케줄링): 학습률을 동적으로 변화

- 훈련 초기에는 학습률을 선형적으로 증가시키고, 이후에는 step number(단계 수)의 inverse square root(역제곱근)에 비례하여 감소
- warmup_steps = 4000

훈련 초기에 학습률을 점진적으로 증가시키는 단계

- 불안정성 방지
- 효율적 학습 목적
- 클수록 빠르게 증가, 작을수록 천천히 증가

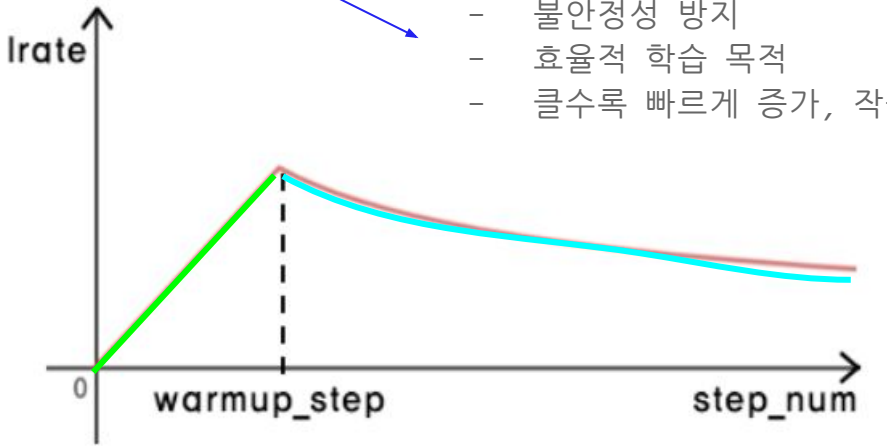

Residual Dropout: 잔차 연결 dropout

- 각 sub layer의 출력에 dropout 적용
- 임베딩과 위치 인코딩에도 dropout 적용
- Base 모델에서 P_{drop} = 0.1 사용

트랜스포머는 훈련 비용의 일부만으로
이전 모델들보다 더 높은 BLEU 점수를 달성함

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.0**	$2.3 \cdot 10^{19}$	

Residual Dropout: 잔차 연결 dropout

- 각 sub layer의 출력에 dropout 적용
- 임베딩과 위치 인코딩에도 dropout 적용
- Base 모델에서 P_{drop} = 0.1 사용

Dropout의 **확률값**을 지정하는 하이퍼파라미터
- 10% 확률로 뉴런을 drop

트랜스포머는 훈련 비용의 일부만으로
이전 모델들보다 더 높은 BLEU 점수를 달성함

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.0**	$2.3 \cdot 10^{19}$	

Residual Dropout: 잔차 연결 dropout

- 각 sub layer의 출력에 dropout 적용
- 임베딩과 위치 인코딩에도 dropout 적용
- Base 모델에서 P_{drop} = 0.1 사용

트랜스포머는 훈련 비용의 일부만으로
이전 모델들보다 더 높은 BLEU 점수를 달성함

기계 번역 결과와 사람이 번역한 참조 번역 간의 **유사도를 측정**하는 자동 평가 지표

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.0**	$2.3 \cdot 10^{19}$	

5.3 Regularization 규제화!

Model	BLEU		Training Cost (FLOPs)	
	EN-DE	EN-FR	EN-DE	EN-FR
ByteNet [15]	23.75			
Deep-Att + PosUnk [32]		39.2		$1.0 \cdot 10^{20}$
GNMT + RL [31]	24.6	39.92	$2.3 \cdot 10^{19}$	$1.4 \cdot 10^{20}$
ConvS2S [8]	25.16	40.46	$9.6 \cdot 10^{18}$	$1.5 \cdot 10^{20}$
MoE [26]	26.03	40.56	$2.0 \cdot 10^{19}$	$1.2 \cdot 10^{20}$
Deep-Att + PosUnk Ensemble [32]		40.4		$8.0 \cdot 10^{20}$
GNMT + RL Ensemble [31]	26.30	41.16	$1.8 \cdot 10^{20}$	$1.1 \cdot 10^{21}$
ConvS2S Ensemble [8]	26.36	**41.29**	$7.7 \cdot 10^{19}$	$1.2 \cdot 10^{21}$
Transformer (base model)	27.3	38.1	**$3.3 \cdot 10^{18}$**	
Transformer (big)	**28.4**	**41.0**	$2.3 \cdot 10^{19}$	

Label Smoothing:

- $\epsilon_{ls} = 0.1$ Label Smoothing 값: 0.1 적용
- Perplexity(혼란도)를 증가시키고, accuracy (정확도)와 BLEU 점수를 개선

Label Smoothing:

- $\epsilon_{ls} = 0.1$ Label Smoothing 값: 0.1 적용
- Perplexity(혼란도)를 증가시키고, accuracy (정확도)와 BLEU 점수를 개선

<레이블을 그대로 사용하는 것이 아니라 조금 smooth하게 만들어서 정규화 시킴>

- Hard target(one-hot) -> Soft target
- [0,1,0,0] -> [0.025, 0.0925, 0.025, 0.025]

- 실제 정확도보다 예측 확률이 큰 상태의 과잉확신을 방지
- 모델의 일반화 성능을 높여줌

06

Results

- Transformer 모델이 RNN, CNN 기반 모델보다 기계번역 작업에서 우수한 성능을 보였다.

English-to-German 번역
(WMT 2014 데이터셋)

Base 모델
> BLEU 점수 : 25.8
> 훈련시간 : 8개의 P100 GPU를 사용해서 3.5일
> 기존보다 빠르고 높은 성능

Big 모델
> BLEU 점수 : 28.4
> 모델 크기 늘리고, Dropout 비율 0.3으로 설정

English-to-French 번역
(WMT 2014 데이터셋)

Big 모델
> BLEU 점수 : 41.0
> 단일 모델 기준 최고 성능
> 훈련 비용도 기존 최고 성능 모델의 ¼ 수준

- 논문은 Transformer 모델의 하이퍼파라미터 성능을 비교한 결과를 표로 설명하고 있다.
- 설명에 들어가기에 앞서, 각 개념을 짚고 넘어가자.

N

Number of Layers : 트랜스포머의 Encoder/Decoder 블록 수를 의미한다.
ex) N=5 라면, Encoder와 Decoder가 각각 5개의 레이어를 가진다는 뜻.
역할 : 레이어가 많아질수록 모델의 깊이가 증가하고, 더 복잡한 패턴을 학습할 수 있다.

d_{model}

Model Dimension : 입력 단어를 벡터로 변환할 때 사용되는 임베딩 벡터의 차원.
ex) d_model =512 라면, 각 단어가 512차원 벡터로 표현된다.
역할 : 모델이 표현할 수 있는 정보의 크기를 결정한다. 커지면 성능이 향상되지만 비용도 증가.

h

Number of Attention Heads: Multi-Head Attention에서 쓰이는 헤드의 개수.
역할 : 여러 헤드가 데이터를 다양한 방식으로 분석해서 더 풍부한 표현을 학습.

d_k, d_v

Key/Value Dimensions: Multi-Head Attention에서 Key와 Value 벡터의 차원 크기.
Key/Value 차원이 작아지면 계산 효율성이 증가하지만, 너무 작으면 성능이 저하된다.

P_{drop}

Dropout Probability : 학습 중 뉴런 출력을 랜덤하게 제거할 확률. 0.1을 값으로 주면 뉴런의 10%를 학습 중에 제거한다. 오버피팅 방지를 위한 드롭아웃 비율이라고 보면 된다.
역할 : 오버피팅 방지 및 일반화 성능 향상

6.2 Model Variations

ϵ_{ls}

Label Smoothing: 레이블 스무딩은 정답 레이블의 확률을 살짝 낮추고, 나머지 클래스에 확률을 조금 나눠주는 기법이다.예를 들어, 0.1을 값으로 주면 정답 레이블 확률을 0.9로, 나머지 클래스에 0.1을 분산시키는 식이다.
역할 : 모델이 과도하게 정답 레이블에 의존하지 않도록 돕고, 일반화 성능을 향상시킨다.

train steps

모델이 학습을 위해 데이터를 몇 번 업데이트 했는지를 나타낸다. 훈련 스텝이 많을수록 더 많은 데이터로 학습하지만, 과적합 위험이 증가할 수 있다.

PPL (dev)

Perplecity : 언어 모델의 성능을 측정하는 척도. 낮을수록 모델이 더 정확한 예측을 한다는 뜻이다.
모델의 품질을 정량적으로 평가하는 역할을 한다.

BLEU (dev)

BLEU Score : 번역 모델의 성능을 평가하는 점수. 높을수록 번역 품질이 좋음을 나타낸다.
번역 작업에서 모델 성능을 직접적으로 평가하는 역할을 한다.

params $\times 10^6$

파라미터 수. 모델에서 학습되는 가중치(파라미터)의 총 개수를 백만 단위로 표현했다.
모델 크기를 평가한다.

6.2 Model Variations

d_{ff} Feed-Forward Dimension : FFN 내부에서 데이터 차원을 확장하는 중간 레이어 차원.

참고 : 선형 변환은 단순히 입출력 간의 선형 관계만 표현할 수 있다.
비선형 변환은 더 복잡한 관계를 모델링하는 과정이다.

피드포워드 네트워크(FFN)란? 앞에도 나왔지만 여기서 간단히 또 짚어보자면
Fully Connected Layer(완전연결층)

트랜스포머의 인코더, 디코더 블록에는 Multi-Head Attention 이후에 Feed-Forward Network가 들어간다. 입력벡터를 비선형적으로 변환하기 위해서다.

더 자세히 설명하자면, Multi-Head Attention에서 계산된 결과는 그대로 사용할 수 없다. Attention 결과를 더 잘 변환하고, 학습 가능한 패턴을 추출하기 위해 FFN을 사용한다.

공식

$$FFN(x) = \mathrm{ReLU}(xW_1 + b_1)W_2 + b_2$$

X : Multi-Head Attention의 출력
W1, W2 : 학습 가능한 가중치 행렬
b1, b2 : 학습가능한 편향(bias)
ReLU : 비선형 활성화 함수

Multi-Head Attention은 각 입력벡터(단어 벡터)에 대해 문맥 정보를 계산한다. 즉, 입력 단어가 문장 내에서 다른 단어들과 어떤 관계에 있는지 학습한다.

단어 간의 관계를 계산하는 데 특화됐지만, 개별 단어 벡터를 풍부하게 변환하는 데는 **한계**가 있다.

예를 들어 rabbit과 sleep의 관계는 잘 표현하지만, rabbit 자체의 특성은 학습에 한계가 있다.

그래서 Multi-Head Attention 이후에 FFN을 추가로 적용하면
Attention이 계산한 문맥 정보를 바탕으로 단어 벡터를 개별적으로 비선형적으로 변환해 더 풍부하게 학습하고, 문맥 속 단어의 의미를 더 깊이 이해할 수 있게 된다.

d_{ff} 를 그래서 왜 쓰는 걸까?

입력데이터(벡터)를 변화하는 것만으로는 충분히 복잡한 패턴을 학습할 수 없다.

FFN은 차원을 dff로 확장해서 더 많은 계산을 수행하고, 데이터를 비선형적으로 변환한다.
결과적으로, 모델이 더 복잡한 관계와 패턴을 학습할 수 있게 된다.

FFN의 **용량**을 결정하는 요소라고 볼 수 있다.

예를 들어 모델 디멘젼이 512, dff가 2048 라면, 입력 벡터의 크기가 512차원이 된다.
FFN의 첫번째 레이어가 512 차원 데이터를 2048차원으로 확장시킨다.

이후 ReLU 함수로 비선형 변환을 적용하고, 두 번째 레이어에서 다시 512차원으로 줄인다.
이 과정을 거쳐 입력 데이터에 대한 더 복잡한 표현을 모델이 학습할 수 있게 된다.

6.2 Model Variations

- Base 모델을 기준으로 다양한 변형 모델((A), (B), (C) 등)을 실험한 결과를 비교하고 있다.

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65
(A)												
(B)												
(C)												
(D)												
(E)												
big	6	1024	4096	16			0.3		300K	**4.33**	**26.4**	213

- **Base 모델**은 기본 설정으로 빠르고 효율적이고, 번역 성능이 준수한 모델이다.
- **Big 모델**은 크기를 키워서 더 높은 성능을 얻었지만, 계산 비용이 더 높은 모델이다.

Base 모델과 Big 모델만 비교해서 먼저 보면

Big 모델이 약 2배 정도씩 더 큰 하이퍼파라미터가 적용됐지만, 결과는 비슷한 걸 볼 수 있다.

6.2 Model Variations

Head가 8, 16일 때 성능이 가장 좋음

기본적으로 사용한 하이퍼파라미터

Head 디멘젼을 바꾸면서 key와 value 디멘젼도 바뀜.

헤드 상관 없이 key 디멘젼 줄이기. 파라미터 수가 줄어서 BLEU도 줄었다.

모델 차원 크기를 늘리거나, FFN 내부 레이어 차원 높였을 때 성능이 좋아진다.

드롭 아웃, 레이블 스무딩도 효과가 있다.

위치 정보를 주는 positional embedding이 기존의 sin, cos 함수를 이용한 인코딩에 비해 성능에 악영향을 미치는지 봤을 때, 해당 요소가 미치는 영향은 미미하다는 걸 알 수 있다.

	N	d_{model}	d_{ff}	h	d_k	d_v	P_{drop}	ϵ_{ls}	train steps	PPL (dev)	BLEU (dev)	params $\times 10^6$
base	6	512	2048	8	64	64	0.1	0.1	100K	4.92	25.8	65
(A)				1	512	512				5.29	24.9	
				4	128	128				5.00	25.5	
				16	32	32				4.91	25.8	
				32	16	16				5.01	25.4	
(B)					16					5.16	25.1	58
					32					5.01	25.4	60
(C)	2									6.11	23.7	36
	4									5.19	25.3	50
	8									4.88	25.5	80
		256			32	32				5.75	24.5	28
		1024			128	128				4.66	26.0	168
			1024							5.12	25.4	53
			4096							4.75	26.2	90
(D)							0.0			5.77	24.6	
							0.2			4.95	25.5	
								0.0		4.67	25.3	
								0.2		5.47	25.7	
(E)	positional embedding instead of sinusoids									4.92	25.7	
big	6	1024	4096	16			0.3		300K	**4.33**	**26.4**	213

07

conclusion

- Transformer는 전적으로 Attention 매커니즘 기반으로 설계된 최초의 모델
- 기존의 RNN, CNN 기반 번역 모델에 비교했을 때 속도, 성능 모두 더 우수하다.
- 특히 번역 성능에서는 기존 기록을 갱신할 정도.

- 앞으로 이미지, 오디오, 비디오 등 다른 분야에도 적용 가능성이 크다.
- 더 큰 입력데이터를 다루기 위해 local Attention 같은 방법을 연구할 예정.